实时人脸替换技术的系统架构与核心算法

——基于 Deep-Live-Cam 开源系统的深度解析*

辛知航

江南大学数学与数据科学学院

摘要

本文对 Deep-Live-Cam 实时人脸替换系统进行系统性的技术解析，深入探讨该系统涵盖的人脸检测与对齐、身份特征提取与迁移、生成对抗网络增强、时序平滑插值以及多级掩膜融合等核心技术模块。文章以学术论文的形式对每一关键算法进行理论推导，涵盖仿射变换矩阵的最小二乘估计、归一化人脸嵌入空间的余弦相似度度量、基于 Poisson 方程的无缝融合理论，以及基于 LAB 色彩空间的颜色迁移方法。同时，本文对系统的实时推理流水线进行性能分析，阐明其在 CPU、CUDA、DirectML 及 CoreML 等异构计算环境下的工程优化策略。研究表明，该系统通过精心设计的模块化架构与多级后处理机制，在保证实时性的同时实现了较高的视觉质量。

*https://github.com/hacksider/Deep-Live-Cam

目录

1 引言 **4**

2 系统整体架构 **4**

2.1 处理流水线概述 4

2.2 模块间数据流 5

3 人脸检测与关键点定位 **5**

3.1 InsightFace 检测框架 5

3.1.1 RetinaFace 多尺度检测 5

3.1.2 2D-106 关键点定位 6

3.2 归一化身份嵌入 6

4 人脸对齐：仿射变换估计 **7**

4.1 问题形式化 7

4.2 部分仿射变换的最小二乘估计 7

4.3 仿射变换的应用 8

5 身份迁移：人脸替换核心模型 **8**

5.1 inswapper 模型的设计原理 8

5.1.1 身份-属性解耦框架 9

5.1.2 自适应实例归一化（AdaIN） 9

5.2 训练目标函数 9

5.3 推理时的不透明度混合 10

6 人脸增强：GAN 后处理 **10**

6.1 GFPGAN 盲人脸修复 10

6.1.1 生成对抗网络基础 11

6.1.2 GFPGAN 的特征调制机制 11

6.1.3 GFPGAN 的联合优化目标 11

6.2 GPEN 模型族 11

6.2.1 增强结果的羽化融合 12

7 多级掩膜融合策略 **12**

7.1 凸包人脸掩膜 12

7.2 口部掩膜与原始口部保留 13

7.2.1 口部区域的多边形构建 13

7.2.2 口部区域的软融合 13

7.3 Poisson 无缝融合 13

7.3.1 Poisson 融合的数学基础 13

7.3.2 引导场的选择 14

8 颜色校正：LAB 色彩空间统计迁移 **14**
8.1 LAB 色彩空间的优势 14
8.2 颜色统计迁移算法推导 14

9 时序平滑：帧间插值 **15**
9.1 问题定义 15
9.2 指数加权移动平均滤波 15
9.3 锐化后处理 16

10 多人脸聚类匹配 **16**
10.1 K-Means 聚类确定人脸质心 16
10.2 最优簇数确定：肘部法则 16
10.3 最近质心分配 17

11 实时推理流水线与硬件加速 **17**
11.1 生产者-消费者双缓冲架构 17
11.2 人脸检测的时序抽帧优化 17
11.3 内存管道视频处理 18
11.4 ONNX Runtime 的多后端加速 18
11.4.1 CUDA IO Binding 优化 18
11.4.2 cuDNN 卷积算法搜索 19

1 引言

人脸替换（Face Swapping）技术是计算机视觉与深度学习交叉领域的重要研究方向，其核心目标是将源图像中某人的外貌特征迁移至目标图像或视频的人脸区域，同时保持目标场景的姿态、表情、光照等上下文信息不变。近年来，随着生成对抗网络（Generative Adversarial Network, GAN）[1] 和大规模人脸分析模型的飞速发展，人脸替换技术在艺术创作、虚拟试妆、影视后期制作等领域展现出巨大的应用潜力。

Deep-Live-Cam 是一个基于 Python 的开源实时人脸替换系统，其技术架构融合了 InsightFace [2] 人脸分析框架、基于 ONNX Runtime 的高效推理引擎、多种人脸增强模型（GFPGAN、GPEN），以及精细化的掩膜融合与颜色校正机制。该系统能够以接近实时的速度（30 FPS 量级）处理摄像头输入，仅需单张源人脸图像即可完成替换。

2 系统整体架构

从读者理解角度看，Deep-Live-Cam 可以被视为一条“先定位、再规整、后生成、再修饰、最后融合”的装配线。系统并不是依赖某一个单一模型直接完成全部工作，而是把几何估计、身份迁移、细节增强与视觉合成拆分为若干职责清晰的阶段。这样的模块化设计不仅便于替换不同模型后端，也使系统能够根据算力条件灵活启用或关闭部分后处理步骤。

2.1 处理流水线概述

Deep-Live-Cam 系统的处理流水线可以形式化地描述为如下映射：

$$\mathcal{F} : (I_s, I_t) \longrightarrow I_o \tag{1}$$

其中 $I_s \in \mathbb{R}^{H_s \times W_s \times 3}$ 为源人脸图像，$I_t \in \mathbb{R}^{H_t \times W_t \times 3}$ 为目标图像或视频帧，$I_o \in \mathbb{R}^{H_t \times W_t \times 3}$ 为输出图像。

整体流水线由以下五个顺序模块构成：

$$I_o = \mathcal{M}_5\big(\mathcal{M}_4\big(\mathcal{M}_3\big(\mathcal{M}_2\big(\mathcal{M}_1(I_s, I_t)\big)\big)\big)\big) \tag{2}$$

其中各模块定义如下：

$$\begin{aligned}
&\mathcal{M}_1 : \text{人脸检测与关键点定位模块} \\
&\mathcal{M}_2 : \text{人脸对齐与特征提取模块} \\
&\mathcal{M}_3 : \text{身份迁移（人脸替换）模块} \\
&\mathcal{M}_4 : \text{人脸增强模块（GAN 后处理）} \\
&\mathcal{M}_5 : \text{掩膜融合与颜色校正模块}
\end{aligned}$$

直观地说，$\mathcal{M}_1$ 回答“画面里哪里有人脸”，$\mathcal{M}_2$ 回答“如何把这张脸摆正到标准坐标系”，$\mathcal{M}_3$ 回答“把谁的身份换进去”，$\mathcal{M}_4$ 负责“把生成结果修得更清晰”，而 $\mathcal{M}_5$ 则负责“如何无

痕贴回原图”。如果先用这五个问题去理解后续公式，再回头看各模块的数学定义，整条流水线的逻辑会更容易把握。

2.2 模块间数据流

设 $\mathbf{f}_s, \mathbf{f}_t \in \mathbb{R}^{512}$ 分别为源人脸和目标人脸的归一化身份嵌入向量（Normalized Identity Embedding），$\mathbf{L}_t \in \mathbb{R}^{5\times 2}$ 为目标人脸的五点关键坐标，则模块间的数据依赖关系可表述为：

$$(\mathbf{L}_t, \mathbf{f}_t, \mathrm{bbox}_t) = \mathcal{M}_1(I_t) \tag{3}$$

$$(\mathbf{f}_s, \mathrm{crop}_s) = \mathcal{M}_2(I_s, \mathcal{M}_1(I_s)) \tag{4}$$

$$I_{\mathrm{swap}} = \mathcal{M}_3(I_t, \mathbf{f}_s, \mathbf{f}_t, \mathbf{L}_t) \tag{5}$$

$$I_{\mathrm{enh}} = \mathcal{M}_4(I_{\mathrm{swap}}) \tag{6}$$

$$I_o = \mathcal{M}_5(I_{\mathrm{enh}}, I_t, \mathbf{L}_t) \tag{7}$$

这里最关键的设计思想，是把“身份信息”和“几何信息”显式解耦。512 维嵌入向量主要描述“这个人是谁”，而关键点与边界框主要描述“这张脸在哪里、姿态如何、应该裁多大范围”。正因为两类信息被分开建模，同一个源身份才可以稳定迁移到不同姿态、不同表情和不同光照条件的目标脸上。

3 人脸检测与关键点定位

3.1 InsightFace 检测框架

系统采用 InsightFace 的 `buffalo_l` 模型集合作为人脸分析后端，从工程实现角度看，检测阶段承担的是“为后续所有模块提供可靠入口”的角色。若检测框偏移、关键点抖动或身份嵌入不稳定，那么这些误差会沿流水线持续放大，最终表现为边缘错位、五官漂移或身份失真。因此，实时换脸系统通常宁愿在检测阶段投入更稳定的分析模型，也不愿在生成阶段被动补救。

该模型集合由 RetinaFace 检测器、ArcFace 识别网络及 2D-106 关键点定位网络组成。

3.1.1 RetinaFace 多尺度检测

RetinaFace [3] 在特征金字塔网络（FPN）的基础上，联合优化人脸边界框回归、人脸-非人脸分类及关键点回归三个任务。设输入图像经过骨干网络（ResNet-50）后得到多尺度特征图 $\{P_3, P_4, P_5\} \subset \mathbb{R}^{C\times H_i\times W_i}$，对于每个尺度上的每个锚框 $\mathbf{a} = (x_a, y_a, w_a, h_a)$，网络输出联合预测：

$$\hat{\mathbf{y}} = \left(\hat{p}_{\mathrm{face}},\ \Delta\mathbf{b},\ \hat{\mathbf{L}}_5\right) \tag{8}$$

其中 $\hat{p}_{\mathrm{face}} \in [0,1]$ 为人脸置信度，$\Delta\mathbf{b} \in \mathbb{R}^4$ 为边界框偏移量，$\hat{\mathbf{L}}_5 \in \mathbb{R}^{5\times 2}$ 为五点关键点坐标。边界框解码采用标准锚框变换：

$$
\begin{aligned}
\hat{x}_c &= x_a + w_a \cdot \Delta x \\
\hat{y}_c &= y_a + h_a \cdot \Delta y \\
\hat{w} &= w_a \cdot e^{\Delta w} \\
\hat{h} &= h_a \cdot e^{\Delta h}
\end{aligned} \tag{9}
$$

多尺度预测后使用非极大值抑制（NMS）过滤重叠检测框：

$$
\text{NMS}: \quad \text{保留 } \hat{\mathbf{b}}_i \text{ 当且仅当 } \nexists j \neq i: \ \text{IoU}(\hat{\mathbf{b}}_i, \hat{\mathbf{b}}_j) > \tau \ \wedge \ \hat{p}_j > \hat{p}_i \tag{10}
$$

其中交并比（IoU）定义为：

$$
\text{IoU}(\mathbf{b}_1, \mathbf{b}_2) = \frac{|\mathbf{b}_1 \cap \mathbf{b}_2|}{|\mathbf{b}_1 \cup \mathbf{b}_2|} \tag{11}
$$

3.1.2 2D-106 关键点定位

系统使用 106 点人脸关键点模型进行精细化几何分析，对普通读者而言，可以把这 106 个关键点理解为一张稠密的人脸几何草图：它不仅标出双眼、鼻尖和嘴角，还描述脸部轮廓、眼睑曲线、嘴唇边缘等更细的局部形状。相较于仅用于粗对齐的 5 点模板，106 点更适合服务于掩膜构建、口部保护和局部融合，因为这些操作需要知道“边界长什么样”，而不只是“脸大致在哪里”。

关键点集合 $\mathbf{L}_{106} = \{(x_i, y_i)\}_{i=1}^{106}$ 涵盖面部轮廓（0–32）、眼部（33–96）、鼻部（97–104）及口部（52–71）等区域。这些关键点被用于后续的掩膜生成与融合，其精度直接影响最终视觉质量。

3.2 归一化身份嵌入

ArcFace [2] 网络将人脸图像映射至超球面上的紧凑嵌入空间。设人脸识别网络为 $\phi: \mathbb{R}^{112\times112\times3} \to \mathbb{R}^{512}$，则归一化身份嵌入定义为：

$$
\mathbf{f} = \frac{\phi(I_{\text{aligned}})}{\|\phi(I_{\text{aligned}})\|_2} \in \mathbb{S}^{511} \tag{12}
$$

其中 $\mathbb{S}^{511}$ 为 512 维单位超球面。两张人脸的身份相似度通过余弦相似度度量：

$$
\text{sim}(\mathbf{f}_1, \mathbf{f}_2) = \mathbf{f}_1^\top \mathbf{f}_2 = \cos\theta \in [-1, 1] \tag{13}
$$

ArcFace 的训练目标函数引入加性角度间隔以增大类间距离、压缩类内方差：

$$
\mathcal{L}_{\text{ArcFace}} = -\frac{1}{N}\sum_{i=1}^{N} \log \frac{e^{s\cdot\cos(\theta_{y_i}+m)}}{e^{s\cdot\cos(\theta_{y_i}+m)} + \sum_{j\neq y_i} e^{s\cdot\cos\theta_j}} \tag{14}
$$

其中 s 为特征尺度因子，m 为角度间隔超参数，θ_{y_i} 为样本与其对应类中心向量之间的夹角。该损失函数促使模型在超球面上学习到几何上可分离的身份表示。

4 人脸对齐：仿射变换估计

4.1 问题形式化

人脸对齐的目标是将检测到的目标人脸规整化至标准正面位置，这一过程之所以必不可少，是因为大多数识别网络与换脸网络都更擅长处理“已经摆正、尺度稳定”的标准化输入。若直接把侧脸、俯仰头或偏移明显的人脸送入生成器，网络必须同时学习身份迁移与几何归一化两个困难问题，最终往往表现为五官比例异常、边缘错位或身份保真度下降。

以消除姿态变化对后续处理的干扰。设标准面部关键点模板为 $\mathbf{T} = \{(t_{x,i}, t_{y,i})\}_{i=1}^{5} \in \mathbb{R}^{5\times 2}$，目标图像中检测到的对应关键点为 $\mathbf{L} = \{(l_{x,i}, l_{y,i})\}_{i=1}^{5} \in \mathbb{R}^{5\times 2}$。

系统采用 FFHQ（Flickr-Faces-HQ）标准面部模板，其五点坐标在 512×512 分辨率下定义如下（以像素为单位）：

$$\mathbf{T}_{512} = \begin{pmatrix} 192.98 & 239.95 \\ 318.90 & 240.19 \\ 256.63 & 314.02 \\ 201.26 & 371.41 \\ 313.09 & 371.15 \end{pmatrix} \tag{15}$$

对应点顺序依次为：左眼、右眼、鼻尖、左口角、右口角。

4.2 部分仿射变换的最小二乘估计

系统采用部分仿射变换（Partial Affine Transform，即相似变换），需要注意的是，这里并未选择最一般的仿射模型，而是只保留旋转、统一缩放与平移。这样的约束虽然减少了自由度，却更符合人脸对齐的先验：真实人脸在进入识别与生成网络前不应被任意剪切或非均匀拉伸，否则会在后续网络尚未开始推理前就引入不自然的几何畸变。其参数空间为旋转角 α、均匀缩放因子 s 和平移向量 (t_x, t_y)，变换矩阵为：

$$\mathbf{M} = \begin{pmatrix} s\cos\alpha & -s\sin\alpha & t_x \\ s\sin\alpha & s\cos\alpha & t_y \end{pmatrix} \in \mathbb{R}^{2\times 3} \tag{16}$$

设 $\mathbf{a} = (s\cos\alpha, s\sin\alpha, t_x, t_y)^\top \in \mathbb{R}^4$ 为待估参数向量，对于第 i 个关键点对约束：

$$\begin{pmatrix} l_{x,i} & -l_{y,i} & 1 & 0 \\ l_{y,i} & l_{x,i} & 0 & 1 \end{pmatrix} \mathbf{a} = \begin{pmatrix} t_{x,i} \\ t_{y,i} \end{pmatrix} \tag{17}$$

将五个关键点的约束联立，构造超定线性方程组：

$$\mathbf{A}\mathbf{a} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{R}^{10\times 4},\ \mathbf{b} \in \mathbb{R}^{10} \tag{18}$$

其中:

$$\mathbf{A} = \begin{pmatrix} l_{x,1} & -l_{y,1} & 1 & 0 \\ l_{y,1} & l_{x,1} & 0 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ l_{x,5} & -l_{y,5} & 1 & 0 \\ l_{y,5} & l_{x,5} & 0 & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} t_{x,1} \\ t_{y,1} \\ \vdots \\ t_{x,5} \\ t_{y,5} \end{pmatrix} \tag{19}$$

最小二乘解为:

$$\hat{\mathbf{a}} = \left(\mathbf{A}^\top \mathbf{A}\right)^{-1} \mathbf{A}^\top \mathbf{b} \tag{20}$$

在实际实现中,系统调用 OpenCV 的 `estimateAffinePartial2D` 函数,该函数使用 LMEDS (Least Median of Squares) 鲁棒估计方法以抵抗关键点定位噪声:

$$\hat{\mathbf{a}} = \arg\min_{\mathbf{a}} \ \mathrm{median}_i \ r_i^2(\mathbf{a}), \quad r_i = \|\mathbf{A}_i \mathbf{a} - \mathbf{b}_i\|_2 \tag{21}$$

4.3 仿射变换的应用

得到变换矩阵 $\mathbf{M}$ 后，通过仿射变换将目标图像 I_t 中的人脸区域裁剪对齐至 $n \times n$ 标准分辨率:

$$I_{\text{aligned}}(\mathbf{x}) = I_t(\mathbf{M}^{-1}\tilde{\mathbf{x}}) \tag{22}$$

其中 $\tilde{\mathbf{x}} = (x, y, 1)^\top$ 为齐次坐标，双线性插值用于处理非整数坐标处的像素值估计:

$$I_t(x, y) \approx \sum_{i=0}^{1} \sum_{j=0}^{1} w_{ij} \cdot I_t(\lfloor x \rfloor + i, \ \lfloor y \rfloor + j) \tag{23}$$

其中双线性权重 $w_{ij} = |x - (\lfloor x \rfloor + 1 - i)| \cdot |y - (\lfloor y \rfloor + 1 - j)|$。
对齐后的人脸图像通过逆仿射变换 $\mathbf{M}^{-1}$ 贴回原图:

$$\mathbf{M}^{-1} = \begin{pmatrix} \cos\alpha/s & \sin\alpha/s & -(t_x \cos\alpha + t_y \sin\alpha)/s \\ -\sin\alpha/s & \cos\alpha/s & (t_x \sin\alpha - t_y \cos\alpha)/s \end{pmatrix} \tag{24}$$

5 身份迁移：人脸替换核心模型

5.1 inswapper 模型的设计原理

系统的人脸替换核心为 `inswapper_128` 模型，该模型基于 SimSwap [4] 与 FSGAN [5] 的设计思想，通过解耦身份信息（Identity）与属性信息（Attribute）实现高保真的人脸替换。

5.1.1 身份-属性解耦框架

设人脸图像空间分解为身份子空间 $\mathcal{V}_{\text{id}}$ 与属性子空间从直觉上看，这一思想可以概括为“源图像提供谁，目标图像提供怎么演”。源脸决定脸型、五官比例和整体身份感；目标脸则保留头部姿态、表情张力、视角、光照与背景语境。换脸模型真正困难之处，不在于简单复制源脸纹理，而在于在不破坏目标动态属性的前提下，把身份信息稳定地注入到结果图像中。

$\mathcal{V}_{\text{attr}}$：

$$\mathcal{V}_{\text{face}} = \mathcal{V}_{\text{id}} \oplus \mathcal{V}_{\text{attr}} \tag{25}$$

属性信息包含姿态 $\mathbf{p}$、表情 $\mathbf{e}$、光照 $\mathbf{l}$ 及背景 $\mathbf{bg}$：

$$\mathbf{a}_t = (\mathbf{p}_t, \mathbf{e}_t, \mathbf{l}_t, \mathbf{bg}_t) = \mathcal{E}_{\text{attr}}(I_t) \tag{26}$$

替换目标为生成图像 I_o 满足：

$$\mathcal{E}_{\text{id}}(I_o) \approx \mathbf{f}_s, \quad \mathcal{E}_{\text{attr}}(I_o) \approx \mathbf{a}_t \tag{27}$$

5.1.2 自适应实例归一化（AdaIN）

inswapper 使用自适应实例归一化（AdaIN）[6] 将源人脸的身份信息注入生成器的中间层特征：

$$\text{AdaIN}(\mathbf{z}, \mathbf{f}_s) = \gamma(\mathbf{f}_s) \cdot \frac{\mathbf{z} - \mu(\mathbf{z})}{\sigma(\mathbf{z})} + \beta(\mathbf{f}_s) \tag{28}$$

其中 $\mathbf{z} \in \mathbb{R}^{C \times H \times W}$ 为编码器提取的目标属性特征，$\mu(\mathbf{z})$ 和 $\sigma(\mathbf{z})$ 为各通道的均值和标准差：

$$\mu_c(\mathbf{z}) = \frac{1}{HW} \sum_{h=1}^{H} \sum_{w=1}^{W} z_{c,h,w} \tag{29}$$

$$\sigma_c(\mathbf{z}) = \sqrt{\frac{1}{HW} \sum_{h=1}^{H} \sum_{w=1}^{W} (z_{c,h,w} - \mu_c)^2 + \epsilon} \tag{30}$$

仿射参数 $\gamma(\mathbf{f}_s), \beta(\mathbf{f}_s) \in \mathbb{R}^C$ 由源身份嵌入向量通过全连接层学习：

$$[\gamma(\mathbf{f}_s); \beta(\mathbf{f}_s)] = \mathbf{W}_{\text{AdaIN}} \mathbf{f}_s + \mathbf{b}_{\text{AdaIN}} \tag{31}$$

5.2 训练目标函数

inswapper 类模型的训练采用多项损失函数联合优化：从优化视角看，多损失联合并不是简单地“多加几个约束”，而是在多个视觉目标之间做平衡。身份损失防止“换得不像”，属性损失防止姿态与表情走样，重建与感知损失抑制纹理退化，而对抗损失则推动结果接近真实图像分布。实践中，系统观感通常取决于这些损失之间的配比是否合理，而不仅是某一项是否被极致最小化。

（1）身份一致性损失：

$$\mathcal{L}_{\text{id}} = 1 - \cos\big(\mathcal{E}_{\text{id}}(I_o),\ \mathbf{f}_s\big) = 1 - \frac{\mathcal{E}_{\text{id}}(I_o)^\top \mathbf{f}_s}{\|\mathcal{E}_{\text{id}}(I_o)\|_2 \cdot \|\mathbf{f}_s\|_2} \tag{32}$$

（2）属性保留损失：

$$\mathcal{L}_{\text{attr}} = \|\mathcal{E}_{\text{attr}}(I_o) - \mathcal{E}_{\text{attr}}(I_t)\|_2^2 \tag{33}$$

（3）重建损失（用于 $I_s = I_t$ 时的自监督）：

$$\mathcal{L}_{\text{rec}} = \|I_o - I_t\|_1 \quad （当 I_s = I_t \text{ 时}） \tag{34}$$

（4）感知损失（Perceptual Loss）：

$$\mathcal{L}_{\text{perc}} = \sum_k \lambda_k \|\phi_k(I_o) - \phi_k(I_t)\|_2^2 \tag{35}$$

其中 $\phi_k(\cdot)$ 为预训练 VGG-19 [9] 第 k 层的特征激活。

（5）对抗损失：

$$\mathcal{L}_{\text{adv}} = -\mathbb{E}_{I_o}\big[\log D(I_o)\big] \tag{36}$$

总损失为加权组合：

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{id}} + \lambda_2 \mathcal{L}_{\text{attr}} + \lambda_3 \mathcal{L}_{\text{rec}} + \lambda_4 \mathcal{L}_{\text{perc}} + \lambda_5 \mathcal{L}_{\text{adv}} \tag{37}$$

5.3 推理时的不透明度混合

系统支持通过不透明度参数 $\alpha_o \in [0, 1]$ 对原始帧与替换结果进行线性混合，以实现平滑过渡效果：

$$I_{\text{blend}} = \alpha_o \cdot I_{\text{swap}} + (1 - \alpha_o) \cdot I_t \tag{38}$$

该操作在像素级逐通道执行，满足线性叠加原理。

6 人脸增强：GAN 后处理

在实际输出中，人眼最敏感的通常不是脸部整体轮廓，而是眼睛、嘴唇、牙齿和皮肤高频纹理等局部细节。换脸核心模型虽然完成了身份迁移，但在这些位置仍可能出现轻微模糊、涂抹感或纹理不连续，因此系统往往会在替换完成后串接专门的人脸修复网络，以提升最终的可感知质量。

6.1 GFPGAN 盲人脸修复

GFPGAN [7]（Generative Facial Prior GAN）是一种基于预训练 StyleGAN2 先验的盲人脸修复（Blind Face Restoration）算法，专为低质量或降质的人脸图像设计。

6.1.1 生成对抗网络基础

标准 GAN 的目标函数定义为二人零和博弈：

$$\min_G \max_D \mathcal{V}(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1-D(G(z)))] \tag{39}$$

在最优判别器 D^* 下，生成器的训练等价于最小化真实数据分布 p_{data} 与生成分布 p_g 之间的 Jensen-Shannon 散度：

$$\mathcal{V}(D^*,G) = -\log 4 + 2\cdot \text{JSD}(p_{\text{data}}\|p_g) \tag{40}$$

6.1.2 GFPGAN 的特征调制机制

GFPGAN 将退化输入 I_{deg} 通过 U-Net 编码器提取多尺度空间特征 $\{F_k^{\text{enc}}\}$，同时利用预训练 StyleGAN2 生成器的强大人脸先验 G_{style} 提供高频纹理信息。

核心创新在于空间特征变换（Spatial Feature Transform，SFT）层，用编码器特征对 StyleGAN2 中间激活进行调制：

$$\text{SFT}(F^{\text{style}}, F^{\text{enc}}) = \gamma(F^{\text{enc}}) \odot F^{\text{style}} + \beta(F^{\text{enc}}) \tag{41}$$

其中 γ, β 为从编码器特征通过卷积层预测的空间调制参数，$\odot$ 表示逐元素乘法。这一机制允许生成器在保持高质量纹理的同时适应输入图像的局部空间结构。

6.1.3 GFPGAN 的联合优化目标

$$\mathcal{L}_{\text{GFPGAN}} = \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{perc}} + \mathcal{L}_{\text{adv}} + \mathcal{L}_{\text{comp}} \tag{42}$$

其中 $\mathcal{L}_{\text{comp}}$ 为分量感知损失（Component-wise Perceptual Loss），专门对眼部和口部区域施加更强约束：

$$\mathcal{L}_{\text{comp}} = \sum_{r\in\{\text{eye}_L,\text{eye}_R,\text{mouth}\}} \|\phi(I_o^{(r)}) - \phi(I_{\text{HQ}}^{(r)})\|_2^2 \tag{43}$$

其中 $I^{(r)}$ 表示图像在局部区域 r 的裁剪。

6.2 GPEN 模型族

GPEN [8]（Generative Prior Embedded Network）采用与 GFPGAN 相似的嵌入式生成先验策略，但使用更紧凑的架构，提供 256×256（GPEN-BFR-256）和 512×512（GPEN-BFR-512）两个规格。

GPEN 的推理流程在 $n \times n$ 分辨率下执行：

$$I_{\text{aligned}} = \mathcal{A}(I_{\text{swap}}, \mathbf{M},\ n) \tag{44}$$

$$\hat{I}_{\text{enh}} = G_{\text{GPEN}}\big(\mathcal{N}(I_{\text{aligned}})\big) \tag{45}$$

$$I_{\text{enh}} = \mathcal{B}(\hat{I}_{\text{enh}}, \mathbf{M}^{-1}, I_{\text{swap}}, \mathbf{mask}) \tag{46}$$

其中 $\mathcal{A}$ 为正向仿射变换，$\mathcal{N}$ 为归一化操作，$\mathcal{B}$ 为带羽化掩膜的反向粘贴操作。

6.2.1 增强结果的羽化融合

增强后的人脸图像通过羽化掩膜融合至替换帧，以避免明显的边界伪影。掩膜 $\mathbf{mask}_\rho$ 构建方式如下：

$$\mathbf{mask}_\rho(i,j) = \prod_{d\in\{0,1\}} w_d(i,j) \tag{47}$$

其中 w_d 为沿第 d 维的线性渐变权重：

$$w_0(i) = \begin{cases} i/b & 0 \le i < b \\ 1 & b \le i < n-b \\ (n-i)/b & n-b \le i < n \end{cases} \tag{48}$$

$b = \lfloor n/16 \rfloor$ 为边界宽度。最终融合为：

$$I_{\text{final}} = \mathbf{mask}_\rho \odot I_{\text{enh,warped}} + (1 - \mathbf{mask}_\rho) \odot I_{\text{swap}} \tag{49}$$

7 多级掩膜融合策略

如果说前面的生成模型决定了“换出来的内容对不对”，那么融合策略决定的就是“看起来像不像真的贴回去了”。许多失败案例并不是身份迁移错误，而是边缘过硬、肤色突变、嘴部形变或局部透明度不自然。因此，多级掩膜实际上是整套系统视觉质量的最后一道保险。

7.1 凸包人脸掩膜

为精确界定人脸区域，系统基于 106 点关键点生成凸包掩膜。设面部轮廓关键点集合为 $\mathcal{P} = \{\mathbf{l}_i\}_{i=0}^{32}$，凸包 $\mathcal{H}(\mathcal{P})$ 定义为包含 $\mathcal{P}$ 的最小凸集：

$$\mathcal{H}(\mathcal{P}) = \Big\{ \sum_i \lambda_i \mathbf{l}_i \,\Big|\, \lambda_i \ge 0,\ \sum_i \lambda_i = 1 \Big\} \tag{50}$$

为确保额头区域被充分覆盖，系统向上延伸额头点：

$$\mathbf{l}_{\text{forehead},k} = \mathbf{l}_{\text{eyebrow},k} + \hat{\mathbf{u}} \cdot \|\mathbf{l}_{\text{eyebrow}} - \mathbf{l}_{\text{chin}}\|_2 \tag{51}$$

其中 $\hat{\mathbf{u}}$ 为从下颌到眉毛的单位向量。凸包掩膜经高斯核 G_σ 平滑以产生渐变边缘：

$$\mathbf{mask}_{\text{face}} = G_\sigma * \mathbf{1}_{\mathcal{H}(\mathcal{P})} \tag{52}$$

7.2 口部掩膜与原始口部保留

口部是实时换脸中最容易暴露伪影的位置之一，因为说话时嘴唇、牙齿与舌头存在高速且非刚性的复杂形变。实践中，一个很常见的策略并不是强迫生成器在所有帧都重新合成完整口部，而是在必要时保留目标原始口部区域，以换取更自然的发音同步、齿列细节与表情连贯性。

口部掩膜技术旨在将原始帧中的口部区域（包含真实的口型运动）覆盖至替换结果之上，从而规避替换模型可能造成的口型不自然问题。

7.2.1 口部区域的多边形构建

设口部关键点集合为 $\mathcal{P}_{\text{mouth}} = \{\mathbf{l}_i\}_{i=52}^{71}$，质心为 $\bar{\mathbf{l}} = |\mathcal{P}_{\text{mouth}}|^{-1} \sum_i \mathbf{l}_i$。各点沿径向方向按比例 $\rho_m \in [1, 3.5]$ 扩展，并对位于质心下方的点额外施加纵向拉伸因子 $\rho_c \in [1, 2.5]$：

$$\mathbf{l}'_i = \bar{\mathbf{l}} + \rho_m \cdot (\mathbf{l}_i - \bar{\mathbf{l}}) \cdot \begin{pmatrix} 1 \\ \rho_c^{\mathbf{1}[l_{y,i} > \bar{l}_y]} \end{pmatrix} \tag{53}$$

7.2.2 口部区域的软融合

设口部掩膜多边形为 $\mathcal{P}'_{\text{mouth}}$，对应的软掩膜为：

$$\mathbf{mask}_m = \frac{G_\kappa * \mathbf{1}_{\mathcal{P}'_{\text{mouth}}}}{\max\left(G_\kappa * \mathbf{1}_{\mathcal{P}'_{\text{mouth}}}\right)} \tag{54}$$

其中 κ 为高斯核标准差，用于羽化多边形边缘。口部复原的最终融合为：

$$I_o^{\text{ROI}} = \mathbf{mask}_m \odot I_t^{\text{ROI}} + (1 - \mathbf{mask}_m) \odot I_{\text{swap}}^{\text{ROI}} \tag{55}$$

其中上标 ROI 表示在口部边界框区域内的操作。

7.3 Poisson 无缝融合

当 Poisson 融合选项启用时，系统使用基于 Poisson 方程的无缝克隆（Seamless Cloning）技术替代线性 Alpha 混合，以进一步消除边界伪影。

7.3.1 Poisson 融合的数学基础

设源区域 Ω 内的替换图像为 I_{swap}，以人脸掩膜边界 $\partial\Omega$ 上的目标图像 I_t 为边界条件，求解以下 Poisson 方程：

$$\Delta I_o = \Delta I_{\text{swap}}, \quad \forall \mathbf{x} \in \Omega \tag{56}$$

$$I_o(\mathbf{x}) = I_t(\mathbf{x}), \quad \forall \mathbf{x} \in \partial\Omega \tag{57}$$

其中 $\Delta = \partial^2/\partial x^2 + \partial^2/\partial y^2$ 为 Laplace 算子。将 Laplace 算子离散化，上述方程化为稀疏线性方程组：

$$\mathbf{L}_\Omega \mathbf{v} = \mathbf{b}, \quad \mathbf{v} = \{I_o(\mathbf{x})\}_{\mathbf{x}\in\Omega} \tag{58}$$

其中 $\mathbf{L}_\Omega$ 为区域 Ω 上的离散 Laplace 矩阵，右端项 $\mathbf{b}$ 包含引导场散度及边界条件。

7.3.2 引导场的选择

在 Normal Clone 模式下，引导场 $\mathbf{v}^*$ 直接取源图像的梯度场：

$$\mathbf{v}^* = \nabla I_{\text{swap}} \tag{59}$$

最终求解：

$$I_o = \arg \min_{f|_{\partial\Omega}=I_t|_{\partial\Omega}} \iint_\Omega \|\nabla f - \mathbf{v}^*\|^2 \, d\mathbf{x} \tag{60}$$

该变分问题的 Euler-Lagrange 方程即为上述 Poisson 方程，其解通过稀疏线性求解器高效计算（OpenCV 的 `seamlessClone` 调用）。

8 颜色校正：LAB 色彩空间统计迁移

颜色校正的必要性来自一个常见事实：源脸和目标脸往往来自不同的拍摄设备、白平衡设置、曝光条件与色调风格。即便几何位置已经精确对齐，若亮度分布与肤色统计量不一致，替换区域依然会像“贴纸”一样从背景中跳出来。因此，颜色迁移实际上是在几何融合之后继续修复视觉一致性。

8.1 LAB 色彩空间的优势

CIE LAB（$L^*a^*b^*$）色彩空间是感知均匀的色彩空间，其三个通道分别编码亮度（L^*）和两个色度分量（a^*, b^*），且各通道间近似统计独立，为颜色统计迁移提供了理想的工作空间。

8.2 颜色统计迁移算法推导

颜色迁移问题可形式化为：寻找变换 $\mathcal{T}$，使得变换后图像的颜色统计量匹配目标图像。假设各 LAB 通道服从高斯分布，最优线性变换为：

$$\mathbf{x}_{\text{out}} = \sigma_t \cdot \frac{\mathbf{x}_s - \mu_s}{\sigma_s} + \mu_t \tag{61}$$

其中 μ_s, σ_s 和 μ_t, σ_t 分别为源图像和目标图像在该通道上的均值和标准差，此变换将源图像的通道分布对齐至目标图像。

对三个 LAB 通道分别独立执行，设第 $c \in \{L, a, b\}$ 通道的操作为：

$$I_{\text{out}}^{(c)} = \frac{\sigma_t^{(c)}}{\sigma_s^{(c)}} \left(I_{\text{source}}^{(c)} - \mu_s^{(c)}\right) + \mu_t^{(c)} \tag{62}$$

为避免 $\sigma_s^{(c)} \approx 0$ 时的数值不稳定，引入正则化：

$$\tilde{\sigma}_s^{(c)} = \max\big(\sigma_s^{(c)},\ \epsilon\big), \quad \epsilon = 10^{-6} \tag{63}$$

完整的颜色迁移流程如下：

1. 将源图像（被替换的人脸裁剪）和目标图像（对应区域）从 $[0, 255]$ 线性映射至 $[0, 1]$
2. 通过 OpenCV 的 `cvtColor` 从 BGR 转换至 $L^*a^*b^*$
3. 对每个通道分别计算统计量并执行上述线性变换
4. 将结果转回 BGR 色彩空间，裁剪至 $[0, 255]$ 范围

此操作在系统的口部掩膜应用阶段执行，确保原始口部区域的颜色与当前替换帧的整体色调保持一致，减少色调不匹配导致的视觉割裂感。

9 时序平滑：帧间插值

对于视频而言，单帧看似正确的结果并不一定稳定。由于检测框、关键点与生成器输出都会随时间产生微小抖动，这些抖动在人眼看来会被放大为闪烁、边缘漂移和纹理跳动。因此，时序平滑并不是可有可无的锦上添花，而是从“静态图像效果”迈向“可连续观看的视频效果”的关键步骤。

9.1 问题定义

在实时视频处理中，逐帧独立处理会导致相邻帧之间的微小不一致性积累，表现为人脸区域的抖动或闪烁。为此，系统引入基于帧间加权平均的时序平滑策略。

9.2 指数加权移动平均滤波

设当前处理帧（第 t 帧）的替换结果为 I_t^{swap}，上一帧的平滑结果为 $\hat{I}_{t-1}$，则时序平滑输出为：

$$\hat{I}_t = w \cdot I_t^{\text{swap}} + (1 - w) \cdot \hat{I}_{t-1} \tag{64}$$

其中 $w = \alpha_{\text{interp}} \in [0, 1]$ 为当前帧权重（插值权重）。展开递推关系：

$$\hat{I}_t = \sum_{k=0}^{t} w(1-w)^{t-k} I_k^{\text{swap}} + (1-w)^{t+1} I_{-1} \tag{65}$$

这等价于以 $(1 - w)$ 为衰减因子的指数加权移动平均（EWMA），其有效时间窗口（半衰期）为：

$$T_{1/2} = \frac{\log 2}{\log(1/(1-w))} \approx \frac{0.693}{w} \text{（当} w \ll 1 \text{ 时）} \tag{66}$$

较小的 w 值对应更长的时间记忆，产生更平滑但略有延迟的输出。系统默认 $w = 0$（即禁用插值），用户可根据场景需求调整。

9.3 锐化后处理

对替换后的人脸区域施加非锐化掩膜（Unsharp Masking）增强细节：

$$I_{\text{sharp}} = I + \sigma_s \cdot (I - G_\sigma * I) = (1 + \sigma_s)I - \sigma_s \cdot G_\sigma * I \tag{67}$$

其中 $\sigma_s \in [0, 5]$ 为锐化强度，G_σ 为高斯模糊核。等价地，使用 `addWeighted` 实现：

$$I_{\text{sharp}} = \texttt{addWeighted}(I,\ 1 + \sigma_s,\ G_\sigma * I,\ -\sigma_s,\ 0) \tag{68}$$

此操作通过 GPU 加速（CUDA/OpenCL）在硬件允许时执行。

10 多人脸聚类匹配

多人脸场景的难点不在于“这一帧里能否检测到几张脸”，而在于“跨帧时能否持续知道每张脸是谁”。如果没有稳定的身份分配机制，系统就可能在相邻帧之间把不同人物错误对应到同一个源脸，从而产生明显的身份跳变。聚类模块的作用，正是把逐帧检测结果提升为跨时间的一致人物索引。

10.1 K-Means 聚类确定人脸质心

在视频的多人脸映射（Map Faces）模式下，系统需要跨帧一致地追踪目标视频中的每个独立人物。这通过对视频帧中所有检测到的人脸嵌入执行 K-Means 聚类实现。

设从视频中采样的人脸嵌入集合为 $\mathcal{E} = \{\mathbf{f}_i\}_{i=1}^N \subset \mathbb{S}^{511}$，K-Means 目标为最小化类内方差：

$$\min_{\{\mathcal{C}_k\}} \sum_{k=1}^{K} \sum_{\mathbf{f} \in \mathcal{C}_k} \|\mathbf{f} - \boldsymbol{\mu}_k\|_2^2 \tag{69}$$

其中 $\boldsymbol{\mu}_k = |\mathcal{C}_k|^{-1} \sum_{\mathbf{f} \in \mathcal{C}_k} \mathbf{f}$ 为第 k 类的质心。

10.2 最优簇数确定：肘部法则

系统通过肘部法则（Elbow Method）自动选择最优簇数 K^*：

$$K^* = \arg \max_{k \in [2, K_{\max}]} \big[\text{Inertia}(k-1) - \text{Inertia}(k)\big] \tag{70}$$

其中惯性（Within-cluster Sum of Squares）为：

$$\text{Inertia}(K) = \sum_{k=1}^{K} \sum_{\mathbf{f} \in \mathcal{C}_k} \|\mathbf{f} - \boldsymbol{\mu}_k\|_2^2 \tag{71}$$

K^* 对应惯性下降幅度最大处，即” 肘部” 位置。

10.3 最近质心分配

推理阶段，对每一帧中检测到的人脸 $\mathbf{f}$，通过余弦相似度确定其所属的最近质心（即对应人物）：

$$k^* = \arg\max_{k\in[1,K^*]} \boldsymbol{\mu}_k^\top \mathbf{f} \tag{72}$$

由于嵌入向量已归一化，余弦相似度等价于内积，计算效率较高。确定人物身份 k^* 后，即可从预设的映射关系中调取对应的源人脸进行替换。

11 实时推理流水线与硬件加速

从工程角度看，实时系统的难点并不只是让单个模型跑得快，而是让多个模块以稳定、低延迟且可持续的方式协同工作。检测、显存拷贝、视频解码、编码、后处理与界面刷新任何一个环节阻塞，都会把理论上的高帧率变成用户可感知的卡顿。因此，本节介绍的优化策略，本质上都是围绕“减少无效等待”和“把计算放到最合适的硬件上”展开。

11.1 生产者-消费者双缓冲架构

系统的实时摄像头处理采用三线程架构以解耦计算瓶颈：

1. **采集线程（Capture Thread）**：持续读取摄像头帧并压入容量为 2 的采集队列 $\mathcal{Q}_{\text{cap}}$；
2. **处理线程（Processing Thread）**：从 $\mathcal{Q}_{\text{cap}}$ 获取原始帧，执行人脸检测、替换、增强，将结果压入显示队列 $\mathcal{Q}_{\text{disp}}$；
3. **显示线程（Display Thread）**：从 $\mathcal{Q}_{\text{disp}}$ 取帧并更新 GUI 预览。

小容量队列（`maxsize=2`）配合”丢旧帧”策略确保系统始终处理最新帧，避免延迟累积：

$$\text{若}\mathcal{Q}\text{ 满:} \quad \text{丢弃 head}(\mathcal{Q}),\ \text{压入新帧至}\mathcal{Q} \tag{73}$$

11.2 人脸检测的时序抽帧优化

人脸检测（包括关键点定位）是流水线中计算开销最大的环节之一。系统通过每 n_{det} 帧执行一次检测、中间帧复用缓存结果的策略降低开销：

$$\hat{F}_t = \begin{cases} \text{DetectFaces}(I_t) & \text{若} t \equiv 0 \pmod{n_{\text{det}}} \\ \hat{F}_{t-(t \bmod n_{\text{det}})} & \text{其他} \end{cases} \tag{74}$$

系统默认 $n_{\text{det}} = 3$，即以约 1/3 的原始频率执行人脸检测，在实时性和精度间取得平衡。

11.3 内存管道视频处理

在批量视频处理模式下，系统采用 FFmpeg 管道（Pipe）方案，通过标准输入/输出流传递原始帧数据，完全规避磁盘 I/O：

1. **解码管道**：FFmpeg 将视频解码为原始 BGR24 帧流，写入 `stdout`
2. **Python 处理**：读取原始字节，重塑为 $H \times W \times 3$ 的 NumPy 数组，执行替换处理
3. **编码管道**：将处理后的帧字节写入编码器的 `stdin`，FFmpeg 直接编码输出

设每帧的字节大小为 $B = H \times W \times 3$，则与磁盘 I/O 方案（写 PNG，$B' \approx B/k_{\text{PNG}}$，$k_{\text{PNG}} \approx 5$，读写各一次）相比，管道方案节省的 I/O 总量约为：

$$\Delta_{\text{IO}} \approx 2N \cdot (B' + B_{\text{meta}}) \text{ 字节} \tag{75}$$

对于 1080p 视频（$B \approx 6.2\,\text{MB}$），管道方案可将每帧 I/O 从约 $2 \times 1.2\,\text{MB} = 2.4\,\text{MB}$ 降至 0，显著提升处理吞吐量。

11.4 ONNX Runtime 的多后端加速

系统通过 ONNX Runtime 统一接口支持多种计算后端：

表 1: 不同执行后端的配置与适用场景

执行提供者	目标硬件	关键优化	典型加速比
CUDAExecutionProvider	NVIDIA GPU	cuDNN, IO Binding	5–20×
DirectMLExecutionProvider	AMD/Intel GPU (Win)	DirectX12 ML	3–10×
CoreMLExecutionProvider	Apple Silicon	Neural Engine	5–15×
CPUExecutionProvider	通用 CPU	OpenMP, AVX2	1× (基准)

11.4.1 CUDA IO Binding 优化

IO Binding 技术允许 ONNX Runtime 直接在 GPU 显存中分配输出张量，避免推理结束后的 GPU→CPU 数据拷贝开销：

$$\underbrace{T_{\text{standard}}}_{\text{标准推理}} = T_{\text{CPU}\to\text{GPU}} + T_{\text{kernel}} + T_{\text{GPU}\to\text{CPU}} \tag{76}$$

$$\underbrace{T_{\text{IOBinding}}}_{\text{IO 绑定推理}} = T_{\text{GPU 只上传}} + T_{\text{kernel}} \tag{77}$$

节省的时间约为 $T_{\text{GPU}\to\text{CPU}} \approx B_{\text{output}}/\text{PCIe BW}$，对于 128×128×3 的人脸张量，节省约 $150\,\mu\text{s}$（PCIe 3.0 x16）。

11.4.2 cuDNN 卷积算法搜索

通过 `cudnn_conv_algo_search=EXHAUSTIVE` 配置，在首次推理时穷举搜索最优的 cuDNN 卷积算法，后续推理复用缓存结果。对于固定输入尺寸（如 128×128），此操作仅执行一次，可将卷积层执行时间降低 20%–40%。

参考文献

[1] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. *Advances in Neural Information Processing Systems*, 27.

[2] Deng, J., Guo, J., Xue, N., & Zafeiriou, S. (2019). ArcFace: Additive angular margin loss for deep face recognition. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 4690–4699.

[3] Deng, J., Guo, J., Ververas, E., Kotsia, I., & Zafeiriou, S. (2020). RetinaFace: Single-shot multi-level face localisation in the wild. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 5203–5212.

[4] Chen, R., Chen, X., Ni, B., & Ge, Y. (2020). SimSwap: An efficient framework for high fidelity face swapping. *Proceedings of the 28th ACM International Conference on Multimedia*, 2003–2011.

[5] Nirkin, Y., Keller, Y., & Hassner, T. (2019). FSGAN: Subject agnostic face swapping and reenactment. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 7184–7193.

[6] Huang, X., & Belongie, S. (2017). Arbitrary style transfer in real-time with adaptive instance normalization. *Proceedings of the IEEE International Conference on Computer Vision*, 1501–1510.

[7] Wang, X., Li, Y., Zhang, H., & Shan, Y. (2021). Towards real-world blind face restoration with generative facial prior. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 9168–9178.

[8] Yang, T., Ren, P., Xie, X., & Zhang, L. (2021). GAN prior embedded network for blind face restoration in the wild. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 672–681.

[9] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.

[10] Blanz, V., & Vetter, T. (1999). A morphable model for the synthesis of 3D faces. *Proceedings of the 26th Annual Conference on Computer Graphics and Interactive Techniques*, 187–194.

[11] Pérez, P., Gangnet, M., & Blake, A. (2003). Poisson image editing. *ACM Transactions on Graphics (TOG)*, 22(3), 313–318.

[12] Reinhard, E., Adhikhmin, M., Gooch, B., & Shirley, P. (2001). Color transfer between images. *IEEE Computer Graphics and Applications*, 21(5), 34–41.